

Evaluation du modele de sentiment

Validation reproduite avec le split deterministe de training.py (random_state=42).

Dataset total: 99 tweets | Entrainement: 79 | Validation: 20

Accuracy entrainement/validation - positive : 0.96 / 0.55 | negative : 0.96 / 0.55

Evaluation positive

Matrice de confusion: lignes = annotation humaine, colonnes = prediction IA.

	ai_not_positive	ai_positive
human_not_positive	5	5
human_positive	4	6

Interpretation : sur 20 tweets de validation, 6 accords sur la classe positive et 5 accords sur son absence (total accords = 11), contre 5 predictions positive non annotees par l'humain et 4 cas positive manques par l'IA (total erreurs = 9). Les accords (11) dépassent les erreurs (9), mais la marge reste faible : le vocabulaire limite du corpus plafonne la generalisation.

classe	precision	rappel	f1	support
not_positive	0.5556	0.5	0.5263	10.0
positive	0.5455	0.6	0.5714	10.0

Evaluation negative

Matrice de confusion: lignes = annotation humaine, colonnes = prediction IA.

	ai_not_negative	ai_negative
human_not_negative	6	4
human_negative	5	5

Interpretation : sur 20 tweets de validation, 5 accords sur la classe negative et 6 accords sur son absence (total accords = 11), contre 4 predictions negative non annotees par l'humain et 5 cas negative manques par l'IA (total erreurs = 9). Les accords (11) dépassent les erreurs (9), mais la marge reste faible : le vocabulaire limite du corpus plafonne la generalisation.

classe	precision	rappel	f1	support
not_negative	0.5455	0.6	0.5714	10.0
negative	0.5556	0.5	0.5263	10.0

Analyse des performances

Une premiere version du modele (TF-IDF en mots, 1-2 grammes) atteignait une accuracy de 1.00 sur l'entrainement contre 0.35 en validation : surapprentissage caracterise, avec des predictions pires que le hasard (0.50 attendu) sur des textes inedits.

Cause identifiee : le corpus de 99 tweets emploie un vocabulaire quasi unique par tweet. Les marqueurs de sentiment presents dans la validation (disappointed, regret, dependable) n'apparaissaient dans aucun tweet d'entrainement : invisibles pour un TF-IDF en mots, dont le vocabulaire est fige au fit. Exemple mesure sur cette version : dans 'I am disappointed with the quality', disappointed etait hors vocabulaire et la prediction reposait sur des mots-outils appris par correlation fortuite (le bigramme 'with the' portait un poids de +0.30), classant la phrase positive a tort.

Correctif applique : vectorisation en n-grammes de caracteres (analyze char_wb, ngram_range 3-5, min_df=2), qui capte des fragments partagees entre mots proches et reduit la dependance au vocabulaire exact.

Resultat apres correctif : accuracy d'entrainement 0.96 et de validation 0.55 (tache positive), 0.96 et 0.55 (tache negative). Le modele repasse au-dessus du hasard et le surapprentissage recule, mais la marge de progression reste liee a la taille et a la diversite lexicale du corpus. Forces du pipeline : evaluation reproductible (split deterministe), predictions coherentes sur le vocabulaire couvert, et reentrainement hebdomadaire qui integrera automatiquement tout enrichissement du dataset.

Analyse des biais

Aucun tweet neutre n'est present dans le dataset, ce qui limite la capacite du modele a distinguer les zones ambigues. Une phrase factuelle peut recevoir un score legerement positif, par exemple autour de +0.11 au lieu de 0.

Le corpus est entierement anglais. Une phrase en francais sort du vocabulaire d'apprentissage et le modele tend a produire un score proche de 0, ce qui traduit davantage une absence de signal qu'une vraie comprehension.

Le jeu de validation ne contient que 99 tweets au total, donc la sous-partie de validation reste tres petite. Les metriques varient facilement selon le split, ce qui rend l'estimation instable.

Recommandations

Enrichir le corpus (250 a 300 tweets) en reutilisant volontairement le vocabulaire du sentiment : chaque marqueur (great, terrible, love, disappointed...) doit apparaitre dans plusieurs tweets pour que le modele puisse en apprendre un poids fiable.

Capitaliser sur le correctif n-grammes de caracteres deja applique (accuracy de validation passee de 0.35 a 0.55 a donnees constantes) : c'est desormais le volume et la diversite du dataset qui limitent la performance, pas la vectorisation.

Ajouter des exemples neutres pour calibrer la zone de decision autour de 0.

Integrer des tweets francais et multilingues pour reduire le biais de langue.

Suivre l'evolution des F1 a chaque reentrainement hebdomadaire (logs/retrain.log) pour detecter toute regression apportee par les nouvelles donnees annotees.