

Evaluation du modele de sentiment

Validation reproduite avec le split deterministe de training.py (random_state=42).

Dataset total: 99 tweets | Entrainement: 79 | Validation: 20

Evaluation positive

Matrice de confusion: lignes = annotation humaine, colonnes = prediction IA.

	ai_not_positive	ai_positive
human_not_positive	3	7
human_positive	6	4

classe	precision	rappel	f1	support
not_positive	0.3333	0.3	0.3158	10.0
positive	0.3636	0.4	0.381	10.0

Evaluation negative

Matrice de confusion: lignes = annotation humaine, colonnes = prediction IA.

	ai_not_negative	ai_negative
human_not_negative	4	6
human_negative	7	3

classe	precision	rappel	f1	support
not_negative	0.3636	0.4	0.381	10.0
negative	0.3333	0.3	0.3158	10.0

Analyse des biais

Aucun tweet neutre n'est present dans le dataset, ce qui limite la capacite du modele a distinguer les zones ambiguës. Une phrase factuelle peut recevoir un score legerement positif, par exemple autour de +0.11 au lieu de 0.

Le corpus est entierement anglais. Une phrase en francais sort du vocabulaire d'apprentissage et le modele tend a produire un score proche de 0, ce qui traduit davantage une absence de signal qu'une vraie comprehension.

Le jeu de validation ne contient que 99 tweets au total, donc la sous-partie de validation reste tres petite. Les metriques varient facilement selon le split, ce qui rend l'estimation instable.

Recommandations

Ajouter des exemples neutres pour mieux calibrer la zone de decision autour de 0.

Integrer des tweets francais et, plus largement, des exemples multilingues pour reduire le biais de langue.

Grossir le dataset pour rendre la validation plus stable et les mesures plus fiables.